UNIVERSIDAD DE CUNDINAMARCA

INFORME ACADÉMICO

Implementación y comparación de algoritmos de clasificación en Machine Learning

Estudiante: Yerson Ronaldo Rivas Ruiz

Asignatura: Introducción a Machine Learning

Actividad: Semana 8 – Algoritmos de clasificación

Año: 2026

1. Introducción

El aprendizaje automático o *Machine Learning* permite desarrollar modelos capaces de identificar patrones en los datos y realizar predicciones a partir de ejemplos previos. Dentro de este campo, los algoritmos de clasificación se utilizan para asignar observaciones a categorías según sus características.

El desempeño de estos algoritmos depende de la naturaleza de los datos, los parámetros utilizados y los criterios de evaluación. Por esta razón, es importante comparar diferentes modelos mediante métricas que permitan conocer tanto su capacidad de clasificación como los errores que pueden cometer.

En este trabajo se implementaron cinco algoritmos de clasificación mediante la biblioteca Scikit-learn: Decision Tree, Random Forest, Support Vector Machine (SVM), K-Nearest Neighbors (K-NN) y Gaussian Naive Bayes. Para realizar la comparación se utilizó el conjunto de datos Breast Cancer Wisconsin Diagnostic, disponible en Scikit-learn.

La evaluación se realizó mediante las métricas Accuracy, Precision, Recall y F1-score, además de matrices de confusión. También se desarrolló una validación cruzada de cinco particiones para complementar el análisis de Random Forest.

El ejercicio tiene fines exclusivamente académicos. Los resultados no constituyen una herramienta de diagnóstico médico ni deben utilizarse para tomar decisiones clínicas.

2. Objetivos

2.1. Objetivo general

Implementar y comparar cinco algoritmos de clasificación en Machine Learning mediante Scikit-learn, utilizando métricas de evaluación y matrices de confusión para identificar sus diferencias de desempeño y justificar la selección de un modelo.

2.2. Objetivos específicos

- Explorar las características y la distribución de clases del conjunto de datos.
- Preparar los datos y dividirlos en conjuntos de entrenamiento y prueba.
- Implementar Decision Tree, Random Forest, SVM, K-NN y Naive Bayes.
- Comparar los modelos mediante Accuracy, Precision, Recall y F1-score.
- Analizar los falsos positivos y falsos negativos de cada clasificador.
- Aplicar validación cruzada para complementar la evaluación de Random Forest.
- Seleccionar un modelo considerando sus resultados y las características del problema.

3. Metodología

3.1. Conjunto de datos

Se utilizó el conjunto Breast Cancer Wisconsin Diagnostic, disponible mediante la función load_breast_cancer(as_frame=True) de Scikit-learn.

El conjunto contiene 569 observaciones y 30 variables numéricas de entrada relacionadas con las características de las muestras. La variable objetivo se transformó para establecer la clase maligna como positiva, representada por el valor 1, y la clase benigna como negativa, representada por el valor 0.

La distribución de las clases fue la siguiente:

Característica	Resultado
Número de observaciones	569
Variables de entrada	30
Casos benignos	357
Casos malignos	212
Valores faltantes en las variables de entrada	0

La distribución muestra una mayor cantidad de casos benignos que malignos. Sin embargo, ambas clases están suficientemente representadas para desarrollar el ejercicio de clasificación.

3.2. Preparación de los datos

Los datos se dividieron en dos conjuntos: 80 % para entrenamiento y 20 % para prueba. Se utilizó random_state=42 para garantizar la reproducibilidad y stratify=y para conservar aproximadamente la proporción original de las clases en ambos conjuntos.

De esta manera, se utilizaron 455 observaciones para el entrenamiento y 114 para la prueba.

3.3. Algoritmos implementados

Se entrenaron los siguientes cinco modelos:

Decision Tree (Árbol de decisión): clasifica las observaciones mediante reglas y divisiones sucesivas de las variables. Se limitó su profundidad a cuatro niveles para controlar su complejidad.

Random Forest: combina múltiples árboles de decisión para generar predicciones. Se configuró con 100 árboles, buscando obtener un modelo con buen desempeño y posibilidad de analizar la importancia de las variables.

Support Vector Machine (SVM): busca establecer una frontera de separación entre las clases. Se utilizó un kernel RBF y se aplicó estandarización de las variables.

K-Nearest Neighbors (K-NN): clasifica cada observación a partir de las clases de sus vecinos más cercanos. Se configuró con cinco vecinos y estandarización de las variables.

Gaussian Naive Bayes: utiliza el teorema de Bayes y supone independencia condicional entre las variables dada la clase. Se implementó mediante GaussianNB().

El escalamiento se aplicó a SVM y K-NN porque estos algoritmos son sensibles a la escala de las variables. Los árboles de decisión, Random Forest y Gaussian Naive Bayes se entrenaron sin este procedimiento.

3.4. Métricas de evaluación

Para comparar los modelos se utilizaron cuatro métricas:

- **Accuracy:** proporción de predicciones correctas sobre el total de observaciones.
- **Precision:** proporción de predicciones positivas que corresponden realmente a casos malignos.
- **Recall:** proporción de casos malignos reales identificados correctamente.
- **F1-score:** media armónica entre Precision y Recall, que permite evaluar el equilibrio entre ambas métricas.

También se utilizaron matrices de confusión para identificar los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos.

En este problema se presta especial atención al Recall y a los falsos negativos, ya que estos últimos representan casos malignos clasificados incorrectamente como benignos.

4. Resultados y comparación de los modelos

Después de entrenar los cinco algoritmos, se evaluó su desempeño sobre el mismo conjunto de prueba de 114 observaciones.

4.1. Tabla comparativa de métricas

Modelo	Accuracy	Precision	Recall	F1-score
Random Forest	97,37 %	100,00 %	92,86 %	96,30 %
SVM	97,37 %	100,00 %	92,86 %	96,30 %
K-NN	95,61 %	97,44 %	90,48 %	93,83 %

Naive Bayes	93,86 %	100,00 %	83,33 %	90,91 %
Decision Tree	91,23 %	94,44 %	80,95 %	87,18 %

Fuente: elaboración propia a partir de los resultados obtenidos en Scikit-learn.

Los resultados muestran que Random Forest y SVM obtuvieron el mejor desempeño general. Ambos alcanzaron una Accuracy del 97,37 %, una Precision del 100 %, un Recall del 92,86 % y un F1-score del 96,30 %.

K-NN presentó un desempeño competitivo, con una Accuracy del 95,61 % y un Recall del 90,48 %. Naive Bayes alcanzó una Precision del 100 %, pero su Recall fue inferior, lo que indica que dejó de identificar más casos malignos que Random Forest y SVM.

Decision Tree obtuvo los resultados más bajos entre los cinco modelos evaluados. Aunque su estructura facilita la interpretación, registró un mayor número de falsos negativos.

4.2. Análisis de las matrices de confusión

La matriz de confusión permite conocer los aciertos y errores de cada clasificador. En este ejercicio, los falsos negativos son particularmente relevantes porque representan casos malignos que fueron clasificados como benignos.

Modelo	Falsos positivos	Falsos negativos	Verdaderos positivos	Verdaderos negativos
Random Forest	0	3	39	72
SVM	0	3	39	72
K-NN	1	4	38	71
Naive Bayes	0	7	35	72

Decision Tree	2	8	34	70

Fuente: elaboración propia a partir de las matrices de confusión generadas en el notebook.

Random Forest y SVM identificaron correctamente 39 de los 42 casos malignos y no registraron falsos positivos. Ambos dejaron tres casos malignos sin identificar.

K-NN identificó 38 casos malignos y presentó cuatro falsos negativos y un falso positivo. Naive Bayes identificó 35 casos malignos, mientras que Decision Tree identificó 34.

Estos resultados demuestran que no es suficiente evaluar un modelo únicamente por su Accuracy. También es necesario examinar el tipo de error cometido y determinar cuáles tienen mayor importancia para el problema estudiado.

4.3. Interpretación general de los resultados

Random Forest y SVM obtuvieron los mejores resultados en las cuatro métricas evaluadas. No obstante, ambos modelos presentaron exactamente el mismo desempeño en el conjunto de prueba, por lo que no es posible afirmar que uno sea predictivamente superior al otro con base en esta evaluación.

K-NN también mostró resultados favorables, aunque cometió un falso positivo y un falso negativo adicional respecto a los dos modelos con mejor desempeño.

Naive Bayes presentó una Precision del 100 %, pero su Recall fue del 83,33 %. Esto significa que todas sus predicciones positivas fueron correctas en este conjunto de prueba, aunque no identificó siete de los 42 casos malignos.

Por su parte, Decision Tree fue el modelo con menor Recall y mayor cantidad de falsos negativos. Esto evidencia que una mayor simplicidad e interpretabilidad no garantiza un mejor desempeño predictivo.

5. Validación cruzada de Random Forest

Se aplicó validación cruzada estratificada de cinco particiones mediante StratifiedKFold y cross_validate.

Este procedimiento divide los datos de entrenamiento en cinco particiones, de manera que el modelo se entrena y evalúa varias veces con diferentes subconjuntos. Se calcularon Accuracy, Precision, Recall y F1-score para examinar el comportamiento de Random Forest en las distintas particiones.

El promedio de cada métrica permite observar el desempeño general del modelo, mientras que la desviación estándar indica cuánto varían los resultados entre las particiones. Una desviación estándar menor sugiere resultados más consistentes en las particiones evaluadas.

La validación cruzada complementa la evaluación del conjunto de prueba, pero no la reemplaza. Para informar los resultados numéricos de este procedimiento deben utilizarse los promedios y las desviaciones estándar que aparecen en la salida correspondiente del notebook.

6. Análisis y respuestas a las preguntas de la guía

6.1. ¿Qué ventaja tiene limitar la profundidad del árbol?

Limitar la profundidad reduce la complejidad del árbol de decisión, facilita su interpretación y puede ayudar a evitar el sobreajuste. Sin embargo, una profundidad demasiado limitada puede impedir que el modelo identifique algunos patrones relevantes de los datos.

6.2. ¿Qué cambia al pasar de un árbol individual a Random Forest?

Random Forest combina las predicciones de múltiples árboles entrenados con muestras y características aleatorizadas. Esta combinación suele reducir la variabilidad de un árbol individual y puede mejorar la capacidad de generalización del modelo.

6.3. ¿Por qué SVM utiliza StandardScaler?

SVM es sensible a la escala de las variables, ya que estas pueden tener magnitudes muy diferentes. StandardScaler transforma las variables para que sean comparables y evita que las de mayor magnitud dominen el proceso de clasificación.

6.4. ¿Qué representa k=5 en K-NN?

Significa que el algoritmo considera los cinco vecinos más cercanos a una observación y utiliza sus clases para determinar la predicción mediante votación.

6.5. ¿Qué supuesto utiliza Naive Bayes?

Naive Bayes supone que las variables son condicionalmente independientes entre sí dada la clase. Gaussian Naive Bayes, además, modela las variables numéricas mediante distribuciones normales dentro de cada clase.

6.6. ¿Qué modelo obtuvo la mayor Accuracy?

Random Forest y SVM obtuvieron la mayor Accuracy, con un 97,37 % cada uno. Ambos clasificaron correctamente 111 de las 114 observaciones del conjunto de prueba.

6.7. ¿Qué modelo obtuvo el mayor Recall para la clase maligna?

Random Forest y SVM alcanzaron el mayor Recall, con un 92,86 %. Ambos identificaron 39 de los 42 casos malignos reales.

6.8. ¿Qué modelos produjeron menos falsos negativos?

Random Forest y SVM, con tres falsos negativos cada uno. Por tanto, fueron los modelos que dejaron menos casos malignos sin identificar en el conjunto de prueba.

6.9. ¿Coincide el modelo con mayor Accuracy con el que seleccionarías?

Sí. Random Forest y SVM obtuvieron la mayor Accuracy y también los mejores valores de Recall y F1-score. Sin embargo, como ambos empataron en las métricas, la selección final puede considerar otros criterios, como la interpretabilidad y la posibilidad de analizar la importancia de las variables.

6.10. Si el costo de no detectar un caso maligno fuera especialmente alto, ¿qué métrica priorizarías?

Priorizaría el Recall de la clase maligna, porque mide la proporción de casos malignos reales identificados correctamente. Un Recall alto implica una menor proporción de falsos negativos. También sería necesario analizar las demás métricas y validar el modelo rigurosamente antes de cualquier aplicación real.

6.11. ¿Cuál es más sencillo de explicar a una persona no técnica?

Decision Tree suele ser más sencillo de explicar porque sus decisiones pueden representarse mediante reglas y ramas. No obstante, en este ejercicio su Recall fue inferior al de Random Forest y SVM, por lo que la facilidad de interpretación debe considerarse junto con el desempeño.

6.12. ¿Qué diferencias observaste entre los algoritmos que requieren escalamiento y los que no?

SVM y K-NN dependen de distancias o de la geometría de los datos, por lo que el escalamiento es importante. Los árboles de decisión y Random Forest se basan en reglas de división y normalmente no lo necesitan. Gaussian Naive Bayes se utilizó sin escalamiento en esta práctica, aunque su desempeño depende de sus supuestos estadísticos y de las características de los datos.

7. Selección del modelo final

Se selecciona Random Forest como modelo final para esta práctica, debido a su alto desempeño y a la posibilidad de complementar las predicciones con un análisis de la importancia de las variables.

El modelo obtuvo una Accuracy del 97,37 %, una Precision del 100 %, un Recall del 92,86 % y un F1-score del 96,30 %. En el conjunto de prueba identificó correctamente 39 de los 42 casos malignos y registró tres falsos negativos.

Sin embargo, SVM obtuvo exactamente las mismas métricas. Por tanto, no se puede afirmar que Random Forest sea predictivamente superior en esta

evaluación. La selección responde también a la posibilidad de analizar la importancia de las variables y complementar la interpretación de los resultados.

Esta decisión se limita al ejercicio académico. Los resultados no validan el uso de ninguno de los modelos para realizar diagnósticos médicos.

8. Conclusiones

La implementación permitió comparar cinco algoritmos de clasificación mediante una misma división de entrenamiento y prueba. El uso de Accuracy, Precision, Recall, F1-score y matrices de confusión facilitó el análisis de sus fortalezas y limitaciones.

Random Forest y SVM obtuvieron los mejores resultados, con una Accuracy del 97,37 %, un Recall del 92,86 % y tres falsos negativos cada uno. Ambos identificaron correctamente 39 de los 42 casos malignos del conjunto de prueba y clasificaron correctamente 72 de los 72 casos benignos.

K-NN presentó un desempeño competitivo, mientras que Naive Bayes y Decision Tree registraron una mayor cantidad de falsos negativos. Esto evidencia la importancia de considerar los tipos de error, además de la exactitud global, al seleccionar un algoritmo de clasificación.

La validación cruzada de cinco particiones permite complementar la evaluación de Random Forest y analizar la variabilidad de sus métricas. Sus resultados deben interpretarse junto con los obtenidos en el conjunto de prueba.

Finalmente, la selección de un modelo depende de las métricas obtenidas, el costo asociado a los errores, la interpretabilidad y las características del problema. En esta práctica se seleccionó Random Forest, sin afirmar que sea predictivamente superior a SVM. Los resultados tienen fines académicos y no deben utilizarse para tomar decisiones clínicas.

9. Referencias

- Scikit-learn. (s. f.). *Breast cancer Wisconsin (diagnostic) dataset*. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_breast_cancer.html
- Scikit-learn. (s. f.). *Model evaluation: quantifying the quality of predictions*. https://scikit-learn.org/stable/modules/model_evaluation.html
- Universidad de Cundinamarca, CADI. (s. f.). *Introducción a Machine Learning: Semana 8. Implementación y comparación de algoritmos de clasificación*. Guía de trabajo asincrónico.